

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP LỚN

HỌC MÁY (CO3117)

NHÓM BTL_10

GVHD: VÕ THANH HÙNG

Sinh viên thực hiện:

Họ và Tên	MSSV
Nguyễn Minh Hạnh	2310895
Huỳnh Cẩm Ly	2312008
Trần Minh Trí	2313627
Phạm Thanh Tín	2313459

TP.HCM, tháng 4, 2026



Bảng phân công nhiệm vụ:

Họ và Tên	MSSV	Nhiệm vụ	Hoàn thành
Nguyễn Minh Hạnh	2310895	• Decision Tree	100%
Trần Minh Trí	2313627	• Tiền xử lý	100%
Huỳnh Cẩm Ly	2312008	• Random Forest	100%
Phạm Thanh Tín	2313459	• Logistic	100%



Mã nguồn: [GitHub](#)



Mục lục

1	Giới thiệu bài toán	6
2	Cơ sở lý thuyết	6
2.1	Decision Tree	6
2.2	Logistic Regression	7
2.3	Random Forest	9
3	Phân tích tập dữ liệu (Exploratory Data Analysis)	10
3.1	Đặc điểm và tính phù hợp của tập dữ liệu	10
3.2	Thách thức của dữ liệu	10
4	Tiền xử lý dữ liệu (Data Preprocessing)	11
4.1	Làm sạch dữ liệu và Mã hóa nhãn	11
4.2	Loại bỏ các đặc trưng đa cộng tuyến	12
4.3	Phân chia tập dữ liệu	12
4.4	Xây dựng đường ống biến đổi	12
4.5	Cân bằng phân bố dữ liệu	13
4.6	Trích xuất và Lựa chọn đặc trưng	14
5	Mô hình và phương pháp	15
5.1	Decision Tree	15
5.1.1	Chiến lược Tinh chỉnh Siêu tham số	15
5.1.2	Lựa chọn Metric Đánh giá	17

5.2	Logistic Regression	17
5.3	Random Forest	18
5.4	Cơ chế hoạt động	18
5.5	Tối ưu hóa siêu tham số bằng Grid Search	18
5.6	Kiểm chứng độ bền vững (K-Fold CV)	19
6	Thực nghiệm & Kết quả	20
6.1	Kết quả mô hình Decision Tree	20
6.1.1	Tinh chỉnh siêu tham số	20
6.1.2	Phân tích Ma trận nhầm lẫn	23
6.1.3	Phân tích Đường cong ROC	24
6.2	Kết quả mô hình Hồi quy Logistic (Logistic Regression)	24
6.2.1	Các chỉ số đánh giá (Metrics)	24
6.2.2	Trực quan hóa kết quả	26
6.3	Kết quả mô hình Random Forest	28
6.3.1	Chỉ số đánh giá tổng quan	28
6.3.2	Trực quan hóa kết quả	29
7	Thảo luận và So sánh hiệu năng các mô hình	31
7.1	Sự ưu việt của mô hình Ensemble (Random Forest)	31
7.2	Sức mạnh dự đoán của Logistic Regression	32
7.3	Giới hạn và Giá trị của Decision Tree	32
8	Kết luận và Hướng phát triển	33



8.1	Kết luận	33
8.2	Hướng phát triển tương lai	33
9	Tài liệu tham khảo	34

1 Giới thiệu bài toán

Bệnh tim mạch hiện là một trong những nguyên nhân gây tử vong hàng đầu trên toàn cầu. Việc phát hiện sớm và chính xác nguy cơ mắc bệnh mang ý nghĩa sống còn trong y tế.

Mục tiêu của bài tập lớn này là áp dụng các kiến thức đã học trong môn Machine Learning để giải quyết một bài toán thực tế: phân loại bệnh nhân có hoặc không có nguy cơ mắc bệnh tim dựa trên các chỉ số sinh lý học (như huyết áp, nhịp tim, nồng độ cholesterol). Bài toán đặt ra thách thức lớn về việc lựa chọn đặc trưng (Feature Selection) và xử lý sự mất cân bằng trong dữ liệu y tế.

2 Cơ sở lý thuyết

Để giải quyết bài toán phân loại nhị phân (Binary Classification), nhóm lựa chọn sử dụng các mô hình sau:

2.1 Decision Tree

Thuật toán Cây quyết định (Decision Tree) phân chia không gian dữ liệu thành các vùng dự đoán thông qua cơ chế rẽ nhánh đệ quy. Dựa trên cấu trúc thực nghiệm, tiêu chuẩn Gini Impurity (chỉ số Gini) được sử dụng làm thước đo mặc định để đánh giá độ đồng nhất tại mỗi nút. Công thức tính chỉ số Gini cho tập dữ liệu với c phân lớp được định nghĩa là:

$$Gini(p) = 1 - \sum_{i=1}^c p_i^2$$

Trong đó, p_i là tỷ lệ mẫu thuộc lớp i .

Mô hình này có ưu điểm trực quan và dễ diễn giải thông qua sơ đồ rẽ nhánh. Tuy nhiên, khi phát triển tự do, thuật toán có xu hướng ghi nhớ toàn bộ

nhiều của dữ liệu huấn luyện, dẫn đến hiện tượng quá khớp (overfitting). Để khắc phục, thuật toán cần được điều chuẩn bằng cách giới hạn cấu trúc vật lý (độ sâu tối đa, số lượng mẫu tối thiểu để phân nhánh) và dịch chuyển ngưỡng xác suất (threshold).

2.2 Logistic Regression

Hồi quy Logistic là thuật toán phân lớp tuyến tính nền tảng, được xây dựng để giải quyết bài toán phân loại nhị phân (Binary Classification). Thay vì dự đoán trực tiếp nhãn lớp, mô hình ước tính **xác suất có điều kiện** $P(y = 1 \mid \mathbf{x})$ — tức xác suất bệnh nhân mắc bệnh tim dựa trên vector đặc trưng đầu vào $\mathbf{x}$.

Hàm Sigmoid (Logistic Function): Để ánh xạ tổ hợp tuyến tính $\theta^T \mathbf{x}$ (có thể nhận giá trị tùy ý trên $\mathbb{R}$) về khoảng xác suất $[0, 1]$, mô hình sử dụng hàm Sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Kết hợp với tổ hợp tuyến tính, hàm giả thuyết của mô hình là:

$$h_{\theta}(\mathbf{x}) = \sigma(\theta^T \mathbf{x}) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

trong đó $\theta \in \mathbb{R}^{n+1}$ là vector tham số (trọng số) của mô hình, n là số lượng đặc trưng. Quy tắc phân lớp được xác định theo ngưỡng quyết định (decision threshold) $\tau = 0.5$:

$$\hat{y} = \begin{cases} 1 & \text{nếu } h_{\theta}(\mathbf{x}) \geq 0.5 \\ 0 & \text{nếu } h_{\theta}(\mathbf{x}) < 0.5 \end{cases}$$

Hàm mất mát — Binary Cross-Entropy (Log Loss): Để học tham số θ từ dữ liệu, mô hình tối thiểu hóa hàm Log Loss trên tập huấn luyện gồm m mẫu:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)})) \right]$$

Hàm mất mát này phạt nặng khi mô hình dự đoán sai với xác suất cao (ví dụ: dự đoán $h_{\theta}(\mathbf{x}) \approx 0$ trong khi nhãn thực $y = 1$), từ đó định hướng quá trình học hướng đến các xác suất chính xác.

Tối ưu hóa: Vì hàm $J(\theta)$ là hàm lồi (convex) theo θ , thuật toán Gradient Descent được áp dụng để tìm nghiệm tối ưu toàn cục. Quy tắc cập nhật tham số tại mỗi bước lặp:

$$\theta_j := \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j} = \theta_j - \frac{\alpha}{m} \sum_{i=1}^m (h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)}) x_j^{(i)}$$

trong đó α là tốc độ học (learning rate). Trong thực tế, thư viện **scikit-learn** sử dụng bộ tối ưu hóa hiệu quả hơn (mặc định là **lbfgs**) thay vì Gradient Descent thuần túy.

Regularization (Chính quy hóa): Để ngăn chặn hiện tượng overfitting, một số dạng chính quy hóa phổ biến được tích hợp vào hàm mất mát. Dạng ℓ_2 (Ridge), được sử dụng mặc định trong **scikit-learn**, bổ sung thêm số hạng phạt vào $J(\theta)$:

$$J_{\text{reg}}(\theta) = J(\theta) + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Tham số $C = 1/\lambda$ trong **scikit-learn** kiểm soát mức độ chính quy hóa: giá trị C nhỏ tương ứng với chính quy hóa mạnh (mô hình đơn giản hơn), và ngược lại.

2.3 Random Forest

Để khắc phục hạn chế về phương sai cao và dễ bị quá khớp của một Cây quyết định đơn lẻ, Random Forest được áp dụng như một thuật toán học kết hợp (Ensemble Learning) mở rộng. Phương pháp này hoạt động dựa trên cơ chế Bagging (Bootstrap Aggregating).

Cụ thể, thuật toán xây dựng một tập hợp gồm nhiều cây quyết định độc lập (**n_estimators**). Mỗi cây được huấn luyện trên một tập dữ liệu con được lấy mẫu ngẫu nhiên có hoàn lại từ tập huấn luyện gốc. Đồng thời, tại mỗi nút rẽ nhánh, thuật toán chỉ xem xét một tập hợp con ngẫu nhiên các đặc trưng (**max_features**).

Kết quả dự đoán cuối cùng của Random Forest là trung bình cộng xác suất (hoặc bình chọn đa số) từ tất cả các cây thành phần. Cơ chế ngẫu nhiên hóa kép này giúp mô hình triệt tiêu các sai số cục bộ, giảm đáng kể hiện tượng overfitting, đồng thời cung cấp khả năng đánh giá mức độ đóng góp của từng biến số (Feature Importance) một cách ổn định và đáng tin cậy hơn.

3 Phân tích tập dữ liệu (Exploratory Data Analysis)

3.1 Đặc điểm và tính phù hợp của tập dữ liệu

Nghiên cứu sử dụng tập dữ liệu bệnh lý tim mạch bao gồm 920 hồ sơ bệnh án với 15 đặc trưng lâm sàng (sau khi sàng lọc sơ bộ) bao trùm các khía cạnh sinh lý học như độ tuổi, giới tính, loại đau thắt ngực, huyết áp, nồng độ cholesterol và kết quả điện tâm đồ. Đây là tập dữ liệu có cấu trúc (*Tabular data*) mang tính chuẩn mực cao trong nghiên cứu y khoa, chứa đựng nhiều mối liên hệ phi tuyến tính phức tạp giữa các đặc trưng. Tính chất đa chiều này khiến nó trở thành ứng cử viên lý tưởng để triển khai các thuật toán Học máy, nhằm khai phá những quy luật bệnh lý ẩn sâu mà các phương pháp thống kê tuyến tính truyền thống khó có thể nắm bắt toàn diện.

3.2 Thách thức của dữ liệu

Thông qua quá trình phân tích khám phá (EDA), nhóm nghiên cứu xác định tập dữ liệu tồn tại ba thách thức cốt lõi, đòi hỏi phải thiết kế một đường ống tiền xử lý (*Preprocessing Pipeline*) chuyên sâu:

- **Dữ liệu khuyết thiếu và sai lệch logic (Missing & Invalid Values):** Nhiều thuộc tính mang tính quyết định chẩn đoán bị thiếu hụt nghiêm trọng, điển hình là *ca* (số mạch máu cản quang, khuyết 66.4%) và *thal* (tình trạng tuần hoàn máu, khuyết 52.8%). Thêm vào đó, tập dữ liệu chứa các giá trị sai lệch logic sinh học (huyết áp và cholesterol bằng 0). Đặc thù này nghiêm cấm việc sử dụng các phương pháp điền khuyết giản đơn (Mean/Median), buộc nhóm phải áp dụng thuật toán nội suy dựa trên không gian đặc trưng như K-Nearest Neighbors (*KNNImputer*).
- **Nhiều và giá trị ngoại lai (Outliers):** Các chỉ số sinh lý (ví dụ: lượng Cholesterol) sở hữu biên độ dao động và phương sai rất lớn. Sự hiện diện của các giá trị ngoại lai có nguy cơ làm chệch hướng trọng số

tối ưu của các mô hình học máy tuyến tính, đặt ra yêu cầu bắt buộc phải áp dụng kỹ thuật chuẩn hóa bền vững (**RobustScaler**).

- **Mất cân bằng phân phối lớp (Class Imbalance):** Số lượng bệnh nhân dương tính với bệnh tim (509 mẫu) chiếm tỷ trọng cao hơn so với nhóm âm tính (411 mẫu). Mặc dù độ chênh lệch không rơi vào mức cực đoan, việc bỏ qua yếu tố này vẫn tiềm ẩn nguy cơ khiến mô hình dự đoán thiên lệch về nhóm đa số (Majority class).

4 Tiền xử lý dữ liệu (Data Preprocessing)

Tiền xử lý dữ liệu là một bước tối quan trọng nhằm đảm bảo mô hình học máy không bị ảnh hưởng bởi nhiễu (noise) và học được các tín hiệu chân đoán chính xác nhất. Dựa trên các đặc tả phân tích khám phá (EDA), quy trình tiền xử lý được thiết kế qua các bước chuyên sâu sau:

4.1 Làm sạch dữ liệu và Mã hóa nhãn

Biến mục tiêu gốc `num` chứa các giá trị từ 0 đến 4, thể hiện các mức độ bệnh tim khác nhau. Để phù hợp với bài toán phân loại nhị phân (Binary Classification), nhãn được quy hoạch lại thành hai lớp: 0 (Không có bệnh tim) và 1 (Có bệnh tim, bao gồm các giá trị > 0). Các thuộc tính định danh không mang ý nghĩa phân tích như `id` và `dataset` được loại bỏ khỏi tập dữ liệu.

Đặc biệt, để giải quyết sai lệch logic sinh học đã phát hiện trong bước EDA, các giá trị 0 bất thường tại cột huyết áp (`trestbps`) và nồng độ cholesterol (`chol`) được chuyển đổi triệt để thành giá trị khuyết thiếu (`NaN`). Bước can thiệp này vô cùng quan trọng, giúp tránh làm sai lệch các chỉ số thống kê và tạo tiền đề để thuật toán nội suy hoạt động chính xác ở giai đoạn sau.

4.2 Loại bỏ các đặc trưng đa cộng tuyến

Sự tồn tại của các biến độc lập có độ tương quan quá cao sẽ gây ra hiện tượng đa cộng tuyến, làm giảm khả năng diễn giải và tính ổn định của mô hình. Hệ số tương quan Pearson được tính toán cho toàn bộ các biến số. Các cặp biến có mức tương quan tuyệt đối lớn hơn 0.9 sẽ được đánh dấu và loại bỏ một biến để giảm thiểu sự dư thừa thông tin.

4.3 Phân chia tập dữ liệu

Để đánh giá mô hình một cách khách quan và tránh hiện tượng rò rỉ dữ liệu (Data Leakage), tập dữ liệu được chia thành tập huấn luyện (Training set) và tập kiểm thử (Test set) theo tỷ lệ 80/20. Kỹ thuật chia phân tầng (*Stratified Split*) được áp dụng dựa trên biến mục tiêu để đảm bảo tỷ lệ lớp nhãn trong cả hai tập là tương đương nhau. Mọi phép biến đổi dữ liệu tiếp theo chỉ được khớp (*fit*) trên tập huấn luyện để duy trì tính độc lập tuyệt đối của tập kiểm thử.

4.4 Xây dựng đường ống biến đổi

Dữ liệu đầu vào bao gồm cả biến số (Numeric) và biến phân loại (Categorical). Một `ColumnTransformer` được thiết lập để xử lý song song hai luồng dữ liệu này:

- **Đối với dữ liệu số (Numerical Features):** Theo nguyên tắc thông thường, các đặc trưng thiếu trên 40% dữ liệu sẽ bị loại bỏ. Tuy nhiên, do hai đặc trưng `ca` và `thal` mang tín hiệu chẩn đoán bệnh lý tim mạch cực kỳ mạnh mẽ, nhóm quyết định giữ lại để bảo toàn sức mạnh dự đoán của hệ thống. Để giải quyết tỷ lệ khuyết thiếu cao này (cùng với các giá trị NaN vừa thiết lập), nhóm sử dụng thuật toán K-Nearest Neighbors (`KNNImputer` với `n_neighbors = 5`) nhằm nội suy dữ liệu dựa trên các hồ sơ bệnh án có đặc điểm tương đồng nhất. Sau đó, dữ liệu được chuẩn hóa bằng `RobustScaler` nhằm triệt tiêu tác động của các giá trị ngoại


lai (Outliers) và đi qua bộ lọc `VarianceThreshold(0.01)` để loại bỏ các thuộc tính gần như không có sự biến thiên.

- **Đối với dữ liệu phân loại (Categorical Features):** Các giá trị khuyết thiếu được điền bằng giá trị xuất hiện nhiều nhất (*Most frequent*). Tiếp đó, kỹ thuật `OneHotEncoder` được áp dụng để chuyển đổi các biến hạng mục thành các vector nhị phân, kết hợp tham số `drop='first'` để tránh bẫy biến giả (Dummy variable trap).
- **Đối với dữ liệu số (Numerical Features):** Do dữ liệu y tế mang tính đặc thù cao, việc điền khuyết bằng trung bình (Mean) hay trung vị (Median) thông thường có thể làm mất đi logic bệnh lý. Nghiên cứu sử dụng thuật toán K-Nearest Neighbors (`KNNImputer` với số láng giềng là 5) để ước lượng và điền khuyết dựa trên các hồ sơ bệnh án có đặc điểm tương đồng nhất. Sau đó, dữ liệu được chuẩn hóa bằng `RobustScaler` nhằm chống lại tác động của các giá trị ngoại lai (Outliers) và đi qua bộ lọc `VarianceThreshold(0.01)` để loại bỏ các thuộc tính gần như không có sự biến thiên.
- **Đối với dữ liệu phân loại (Categorical Features):** Các giá trị khuyết thiếu được điền bằng giá trị xuất hiện nhiều nhất (*Most frequent*). Tiếp đó, kỹ thuật `OneHotEncoder` được áp dụng để chuyển đổi các biến hạng mục thành các vector nhị phân, kết hợp tham số `drop='first'` để tránh bẫy biến giả (Dummy variable trap).

4.5 Cân bằng phân bố dữ liệu

Sự mất cân bằng giữa nhóm mẫu có bệnh và không bệnh có thể khiến mô hình dự đoán thiên lệch về nhóm đa số. Thuật toán SMOTE (Synthetic Minority Over-sampling Technique) được áp dụng riêng trên tập huấn luyện sau khi đã qua bước Pipeline mã hóa.

Để chứng minh tính an toàn của SMOTE, thuật toán nén chiều PCA (Principal Component Analysis) được sử dụng để chiếu dữ liệu xuống không gian 2D. Kết quả trực quan hóa (Hình 1) cho thấy các điểm dữ liệu nhân tạo do SMOTE sinh ra hòa hợp hoàn hảo vào vùng dữ liệu thực tế của nhóm thiểu số, không tạo ra các nhiễu loạn xa lạ.



Hình 1: So sánh cấu trúc không gian dữ liệu (PCA 2D) Trước và Sau khi áp dụng SMOTE.

4.6 Trích xuất và Lựa chọn đặc trưng

Sau quá trình mã hóa One-Hot, không gian đặc trưng bị mở rộng đáng kể. Để tối ưu hóa chi phí tính toán và ngăn chặn hiện tượng quá khớp (Overfitting), kỹ thuật **SelectKBest** được áp dụng. Tiêu chí đánh giá là **Mutual Information** (`mutual_info_classif`) thay vì ANOVA, bởi Mutual Information có khả năng nắm bắt cả các mối quan hệ phi tuyến tính phức tạp giữa triệu chứng và bệnh lý. Thuật toán đã chọn lọc và giữ lại 15 đặc trưng có điểm số thông tin (Information Gain) cao nhất để đưa vào huấn luyện mô hình.

5 Mô hình và phương pháp

5.1 Decision Tree

5.1.1 Chiến lược Tinh chỉnh Siêu tham số

Để kiểm soát overfitting, bốn siêu tham số cốt lõi được đưa vào không gian tinh chỉnh, chia thành hai nhóm mục tiêu:

- **Kiểm soát độ phức tạp cây:** Các tham số `max_depth` (độ sâu tối đa), `min_samples_split` (số mẫu tối thiểu để chia nút) và `min_samples_leaf` (số mẫu tối thiểu tại lá) đóng vai trò thiết lập điều kiện dừng, ngăn cây phát triển quá mức và ghi nhớ nhiều cục bộ trong dữ liệu huấn luyện.
- **Kiểm soát không gian đặc trưng:** Tham số `max_features` giới hạn số đặc trưng được xem xét tại mỗi lần phân nhánh, với ba lựa chọn được khảo sát: `sqrt`, `log2` và `None` (toàn bộ đặc trưng).

Hai tham số `criterion` và `class_weight` được cố định ở giá trị mặc định, lần lượt là `gini` và `None` — do dữ liệu có phân phối lớp tương đối cân bằng.

Quy trình tinh chỉnh được triển khai qua ba bước tuần tự:

Bước 1: Coarse Tuning (Dò thô với Randomized Search).

Không gian tham số rộng được xây dựng với các giá trị ứng viên đa dạng cho từng siêu tham số:

- `max_depth` $\in \{3, 5, 7, 9, 11, 13, 15, \text{None}\}$
- `max_features` $\in \{\text{sqrt}, \text{log2}, \text{None}\}$
- `min_samples_split` $\in \{2, 5, 8, 10, 15, 20\}$
- `min_samples_leaf` $\in \{1, 2, 4, 6, 8, 10, 12\}$

Thay vì duyệt vét cạn toàn bộ lưới có thể lên đến hàng nghìn tổ hợp, thuật toán `RandomizedSearchCV` được dùng để lấy mẫu ngẫu nhiên 200 tổ hợp,

giúp rút ngắn thời gian tính toán trong khi vẫn bao quát tốt không gian khảo sát. Mỗi tổ hợp được đánh giá qua 10-fold cross-validation với metric F1-Score, nhằm ước lượng hiệu suất tổng quát hóa một cách tin cậy.

Bước 2: Fine Tuning (Dò tinh với Grid Search).

Từ bộ tham số tốt nhất tìm được ở Bước 1, một lưới tham số hẹp hơn được xây dựng tự động bằng cách lấy các giá trị ± 2 và $+4$ quanh từng giá trị tốt nhất (có kiểm tra biên để tránh giá trị không hợp lệ). Cụ thể:

- $\text{max_depth} \in \{d - 2, d, d + 2, d + 4\}$
- $\text{min_samples_split} \in \{ms - 2, ms, ms + 2, ms + 4\}$
- $\text{min_samples_leaf} \in \{ml - 2, ml, ml + 2, ml + 4\}$
- max_features được cố định theo giá trị tốt nhất từ Bước 1

GridSearchCV với 10-fold CV quét vét cạn lưới hẹp này để chốt hạ bộ tham số cuối cùng.

Bước 3: Threshold Tuning (Điều chỉnh ngưỡng phân loại).

Sau khi chốt cấu trúc mô hình, ngưỡng phân loại được điều chỉnh thay vì giữ mặc định 0.5. Thuật toán quét dải xác suất từ 0.25 đến 0.70 với bước nhảy 0.01, tính điểm kết hợp Combined tại mỗi ngưỡng τ theo công thức:

$$\text{Combined}(\tau) = w \cdot \text{F1}(\tau) + (1 - w) \cdot \text{Accuracy}(\tau), \quad w = 0.5 \quad (1)$$

trong đó $w = 0.5$ phản ánh mức độ ưu tiên ngang nhau giữa F1-Score và Accuracy. Ngưỡng tối ưu τ^* được xác định là:

$$\tau^* = \arg \max_{\tau \in [0.25, 0.70]} \text{Combined}(\tau) \quad (2)$$

Kỹ thuật này đặc biệt phù hợp với bài toán y tế: ngưỡng mặc định 0.5 không nhất thiết là tối ưu, và việc điều chỉnh ngưỡng cho phép kiểm soát sự đánh đổi giữa Độ nhạy (giảm bỏ sót bệnh) và Độ đặc hiệu (giảm cảnh báo giả) mà không cần huấn luyện lại mô hình.

5.1.2 Lựa chọn Metric Đánh giá

Nhóm sử dụng bộ metric đa chiều thay vì chỉ dùng Accuracy đơn thuần, với lý do cụ thể như sau:

Bảng 1: Các metric đánh giá và lý do lựa chọn

Metric	Lý do lựa chọn
F1-Score	Cân bằng giữa Precision và Recall; được dùng làm tiêu chí tối ưu trong cả hai bước Randomized Search và Grid Search
Sensitivity (Recall)	Đo tỷ lệ phát hiện đúng người bệnh; trong y tế, bỏ sót bệnh nhân là rủi ro lớn hơn cảnh báo nhầm
Specificity	Đo tỷ lệ xác định đúng người khỏe; tránh chẩn đoán sai gây lo lắng không cần thiết
ROC-AUC	Đánh giá khả năng phân biệt tổng quát của mô hình ở mọi ngưỡng, độc lập với τ^* được chọn
Accuracy	Thước đo tổng quát, dễ hiểu; được dùng kết hợp với F1-Score trong bước Threshold Tuning

5.2 Logistic Regression

Cấu hình siêu tham số: Mô hình được khởi tạo với cấu hình tối giản, không thực hiện tinh chỉnh tham số (hyperparameter tuning) vì đây là baseline tuyến tính phục vụ mục đích đối chiếu:

- `max_iter=1000`: Tăng số vòng lặp tối đa để đảm bảo thuật toán hội tụ hoàn toàn trên tập dữ liệu đã chuẩn hóa.
- `random_state=42`: Cố định seed để đảm bảo tính tái lập kết quả.

Quy trình huấn luyện: Dữ liệu đầu vào là tập `heart_train_cleaned.csv` đã qua tiền xử lý (gồm 736 mẫu, 28 đặc trưng sau One-Hot Encoding và

StandardScaler). Mô hình được huấn luyện trực tiếp trên tập này mà không cần pipeline bổ sung, vì bước chuẩn hóa đã được áp dụng trước đó bởi thành viên phụ trách tiền xử lý. Ngưỡng phân lớp mặc định $\tau = 0.5$ được giữ nguyên.

5.3 Random Forest

Random Forest là một thuật toán học máy mạnh mẽ thuộc nhóm Ensemble Learning, dựa trên kỹ thuật Bagging (Bootstrap Aggregating) và sự ngẫu nhiên hóa đặc trưng.

5.4 Cơ chế hoạt động

- **Bootstrap Sampling:** Từ tập dữ liệu huấn luyện (814 mẫu), thuật toán thực hiện lấy mẫu ngẫu nhiên có hoàn lại để tạo ra các tập dữ liệu con song song cho từng cây quyết định.
- **Feature Randomness:** Tại mỗi nút chia, thay vì xét toàn bộ đặc trưng, thuật toán chỉ chọn ngẫu nhiên một nhóm đặc trưng ($\sqrt{features}$) để tìm điểm chia tối ưu, giúp giảm sự tương quan giữa các cây.
- **Aggregating:** Kết quả dự đoán cuối cùng là sự kết hợp (Voting) của 300 cây đơn lẻ, giúp giảm thiểu hiện tượng Overfitting và nâng cao độ ổn định.

5.5 Tối ưu hóa siêu tham số bằng Grid Search

Để tránh Overfitting và tìm ra điểm cân bằng giữa Bias và Variance, bộ tham số tốt nhất đã được xác định qua **GridSearchCV** với **10-Fold Cross-Validation**:

- `n_estimators = 300`: Số lượng cây được tăng lên để đạt độ hội tụ tốt hơn.
- `max_depth = 20`: Độ sâu cho phép cây học được các quy luật phức tạp.

- `min_samples_split = 2` và `min_samples_leaf = 1`: Cấu hình cho phép mô hình khai thác chi tiết các điểm dữ liệu.
- `max_features = 'sqrt'`: Sử dụng căn bậc hai số lượng đặc trưng tại mỗi điểm chia.

5.6 Kiểm chứng độ bền vững (K-Fold CV)

Kết quả đánh giá qua 10-Fold CV trên tập huấn luyện đạt mức Accuracy trung bình **83.42%**. Độ lệch chuẩn (Std Dev) đạt **4.13%**, cho thấy hiệu năng mô hình có sự biến thiên nhất định tùy theo phân đoạn dữ liệu nhưng nhìn chung vẫn giữ được độ tin cậy ổn định trên 80%.

6 Thực nghiệm & Kết quả

6.1 Kết quả mô hình Decision Tree

6.1.1 Tinh chỉnh siêu tham số

Trước tinh chỉnh - Mô hình baseline

Mô hình Decision Tree với tham số mặc định cho thấy dấu hiệu overfitting rõ ràng: Train Accuracy đạt 100% trong khi Test Accuracy chỉ ở mức 76.63%, tạo ra khoảng cách 23.37%. ROC-AUC baseline ở mức 0.7629 cho thấy còn nhiều dư địa để cải thiện.

Bảng 2: Kết quả đánh giá mô hình baseline


Chỉ số	Giá trị
Train Accuracy	100.00%
Test Accuracy	76.63%
ROC-AUC	0.7629
Sensitivity (Recall)	0.7941
Specificity	0.7317
F1-Score (Test)	0.7902

Sau tinh chỉnh - Quy trình Coarse-to-Fine Tuning

Bước 1: Coarse Tuning: Sau thời gian tìm kiếm trên 200 tổ hợp ngẫu nhiên, bộ tham số tốt nhất gồm

- `max_depth=9`
- `max_features=None`
- `min_samples_split=8`
- `min_samples_leaf=12`

Đạt F1-Score (CV=10) = 0.7997.



Hình 2: Phân tích độ nhạy của từng siêu tham số (Coarse Tuning)

Biểu đồ (Hình 2) cho thấy `max_depth` ảnh hưởng rõ rệt nhất, với vùng 7–11 cho kết quả tốt hơn. Việc `max_features=None` được chọn gợi ý cơ chế kiểm soát overfitting chủ yếu đến từ `min_samples_leaf=12`.

Bước 2: Fine Tuning: Lưới hẹp quanh kết quả Bước 1 được quét vét cạn. Bộ tham số chốt:

- `max_depth=9`
- `max_features=None`
- `min_samples_split=6`
- `min_samples_leaf=12`

F1-Score (CV=10) = 0.7997 — ổn định, cho thấy vùng tham số đã hội tụ.

Bước 3: Threshold Tuning: Áp dụng công thức (1) và (2), quá trình quét ghi nhận năm lần cập nhật kỷ lục trước khi hội tụ tại $\tau^* = 0.37$.

Bảng 3: Quá trình tìm ngưỡng phân loại tối ưu

Ngưỡng	F1-Score	Accuracy	Combined
0.25	0.8261	78.26%	0.8043
0.26	0.8297	78.80%	0.8089
0.31	0.8319	79.35%	0.8127
0.32	0.8416	80.98%	0.8257
0.37	0.8519	82.61%	0.8390

→ **Ngưỡng tối ưu** $\tau^* = 0.37$, Combined Score = 0.8390. Ngưỡng thấp hơn 0.5 phản ánh xu hướng ưu tiên phát hiện ca bệnh của mô hình trên tập dữ liệu này.


Bảng 4 tổng hợp so sánh trước và sau tinh chỉnh.

Bảng 4: So sánh các chỉ số trước và sau tinh chỉnh

Chỉ số	Baseline	Sau Tuning	Δ
Accuracy	76.63%	82.61%	+5.98%
ROC-AUC	0.7629	0.8873	+0.1244
Sensitivity (Recall)	0.7941	0.9020	+0.1079
Specificity	0.7317	0.7317	± 0.000
F1-Score	0.7902	0.8519	+0.0617

Hầu hết các metric đều cải thiện hoặc giữ nguyên. Đáng chú ý, Specificity không đổi trong khi Sensitivity tăng 10.79 điểm phần trăm, gợi ý mô hình cải thiện chất lượng phân biệt thực sự chứ không chỉ đơn thuần dịch chuyển ngưỡng.


6.1.2 Phân tích Ma trận nhầm lẫn



Hình 3: Ma trận nhầm lẫn của mô hình Decision Tree (Threshold = 0.37)

Tại ngưỡng 0.37, mô hình phân loại đúng 92/102 ca bệnh (TP = 92, Sensitivity = 90.20%) và 60/82 người khỏe (TN = 60, Specificity = 73.17%). Có 10 trường hợp bị bỏ sót (FN) và 22 cảnh báo nhầm (FP). Tỷ lệ FN thấp hơn FP phù hợp với định hướng ưu tiên an toàn lâm sàng, khi chi phí bỏ sót ca bệnh thường được xem là nghiêm trọng hơn cảnh báo nhầm.

6.1.3 Phân tích Đường cong ROC



Hình 4: Đường cong ROC của mô hình Decision Tree (Baseline vs. Sau Tuning)

AUC sau tinh chỉnh đạt **0.8873**, tăng đáng kể so với baseline 0.7629 (+0.1244), nằm trong khoảng được đánh giá là *tốt* (0.80–0.90). Điều đáng chú ý là AUC — vốn không phụ thuộc vào ngưỡng — vẫn tăng mạnh trong khi Specificity giữ nguyên, gợi ý rằng tinh chỉnh đã cải thiện thực sự khả năng phân biệt của mô hình, không chỉ nhờ điều chỉnh ngưỡng.

6.2 Kết quả mô hình Hồi quy Logistic (Logistic Regression)

6.2.1 Các chỉ số đánh giá (Metrics)


Mô hình Hồi quy Logistic được huấn luyện trên 814 mẫu (15 đặc trưng) và đánh giá trên tập kiểm tra gồm 184 mẫu. Bảng 5 tổng hợp toàn bộ các chỉ số hiệu suất.

Bảng 5: Các chỉ số đánh giá hiệu suất — Logistic Regression

Metric	Giá trị
Accuracy	83.70%
ROC-AUC	0.896
Sensitivity (Recall)	0.87
Specificity	0.79
F1-Score (Có bệnh)	0.86
F1-Score (Không bệnh)	0.81

- **Accuracy (83.70%):** Mô hình phân loại đúng 154/184 mẫu trên tập kiểm tra. Đây là mức độ chính xác đáng tin cậy, đặc biệt khi xét đến tính chất phi tuyến vốn có của dữ liệu y tế và ràng buộc tuyến tính của thuật toán.
- **Sensitivity — Recall lớp Có bệnh (0.87):** Trong số 102 bệnh nhân thực sự mắc bệnh, mô hình nhận diện đúng 89 trường hợp. Đây là chỉ số quan trọng nhất trong bối cảnh y tế, nơi bỏ sót ca bệnh (False Negative) gây hậu quả nghiêm trọng hơn so với cảnh báo nhầm.
- **Specificity — Recall lớp Không bệnh (0.79):** Trong số 82 bệnh nhân khỏe mạnh, mô hình xác định đúng 65 trường hợp. Chỉ số này phản ánh khả năng tránh cảnh báo nhầm (False Positive) của mô hình.
- **ROC-AUC (0.896):** Chỉ số AUC đạt 0.896 cho thấy mô hình có khả năng phân biệt tốt giữa hai lớp ở mọi ngưỡng quyết định. Giá trị này chứng minh rằng mặc dù là mô hình tuyến tính đơn giản, Logistic Regression vẫn nắm bắt được quan hệ phân biệt lớp hiệu quả nhờ bước chuẩn hóa đặc trưng (StandardScaler) được thực hiện trước đó.

6.2.2 Trực quan hóa kết quả



Hình 5: Confusion Matrix — Logistic Regression

Ma trận nhầm lẫn thu được trên tập kiểm tra (184 mẫu) được trình bày trong Bảng 6 và Hình 5.


Bảng 6: Confusion Matrix của mô hình Logistic Regression

	Dự đoán: Không bệnh	Dự đoán: Có bệnh
Thực tế: Không bệnh (82 mẫu)	65 (TN)	17 (FP)
Thực tế: Có bệnh (102 mẫu)	13 (FN)	89 (TP)

- **True Positive (TP = 89):** Số bệnh nhân mắc bệnh được mô hình dự đoán đúng là có bệnh.
- **True Negative (TN = 65):** Số bệnh nhân khỏe mạnh được mô hình dự đoán đúng là không bệnh.

- **False Negative (FN = 13):** Số bệnh nhân thực sự mắc bệnh nhưng bị bỏ sót (dự đoán là không bệnh). Đây là loại lỗi cần đặc biệt quan tâm trong ứng dụng lâm sàng.
- **False Positive (FP = 17):** Số bệnh nhân khỏe mạnh bị cảnh báo nhầm là có bệnh.

Tỷ lệ FN/FP tương đối cân bằng (13 vs 17) cho thấy mô hình không bị lệch về phía nào một cách rõ rệt, phù hợp với phân bố lớp hơi mất cân bằng của tập dữ liệu (509 mẫu Có bệnh vs 411 mẫu Không bệnh).



Hình 6: ROC Curve — Logistic Regression (AUC = 0.896)

Đường cong ROC (Hình 6) được xây dựng bằng cách thay đổi ngưỡng quyết định từ 0 đến 1 và tính toán cặp (False Positive Rate, True Positive Rate) tương ứng. Diện tích dưới đường cong (AUC = 0.896) cho thấy:

- Mô hình có khả năng phân biệt lớp tốt, với xác suất 89.6% để xếp hạng đúng một cặp mẫu ngẫu nhiên (một có bệnh, một không có bệnh).
- Đường cong ROC nằm rõ ràng phía trên đường cơ sở (Random Classifier — đường chéo), xác nhận tính hữu ích thực tiễn của mô hình.

6.3 Kết quả mô hình Random Forest

6.3.1 Chỉ số đánh giá tổng quan

Bảng 7: Hiệu năng Random Forest sau khi tối ưu

Chỉ số	Giá trị	Ý nghĩa
Accuracy	87.50%	Độ chính xác tổng thể
ROC-AUC	0.9189	Khả năng phân loại xuất sắc
Sensitivity (Recall)	0.9216	Hạn chế bỏ sót bệnh nhân
Specificity	0.8171	Khả năng loại trừ người khỏe mạnh


Để đánh giá mức độ tin cậy của mô hình trong môi trường lâm sàng, nhóm tác giả thực hiện phân tích sâu vào các chỉ số trọng yếu:

- **Độ chính xác tổng thể (87.50%):** Với việc dự đoán đúng 161/184 mẫu, mô hình chứng minh sự ổn định cao. Kết quả này cao hơn mức trung bình K-Fold (83.42%), cho thấy quá trình tối ưu hóa siêu tham số đã giúp mô hình đạt được trạng thái tổng quát hóa (*Generalization*) tốt, không bị hiện tượng học vẹt dữ liệu.
- **Khả năng nhận diện bệnh nhân (Recall = 92.16%):** Đây là con số quan trọng nhất trong y tế. Với mức dự đoán đúng 94/102 ca có bệnh, mô hình chỉ bỏ sót khoảng 8% bệnh nhân thực tế. Việc tối ưu hóa chỉ số này giúp giảm thiểu tối đa rủi ro "bỏ sót bệnh", đảm bảo bệnh nhân được can thiệp điều trị kịp thời.
- **Độ đặc hiệu (Specificity = 81.71%):** Mặc dù thấp hơn Recall, nhưng con số này vẫn đảm bảo khả năng loại trừ người khỏe mạnh ở mức khá. Sự chênh lệch này cho thấy mô hình có xu hướng **thận trọng** — ưu tiên việc không bỏ sót ca bệnh hơn là việc chẩn đoán chính xác tuyệt đối người khỏe mạnh. Đây là một sự đánh đổi (*Trade-off*) hợp lý trong sàng lọc chẩn đoán sớm.
- **Diện tích dưới đường cong (AUC = 0.9189):** Chỉ số này tiệm cận mức 0.92 khẳng định khả năng tách biệt lớp dữ liệu (*Separation ability*)

cực kỳ tốt. Điều này chứng minh rằng mô hình có thể phân loại chính xác mức độ rủi ro của bệnh nhân mà không phụ thuộc vào việc lựa chọn ngưỡng phân loại (*Threshold*).

6.3.2 Trực quan hóa kết quả

Phân tích Ma trận nhầm lẫn (Confusion Matrix)



Hình 7: Ma trận nhầm lẫn của mô hình Random Forest


Ma trận nhầm lẫn cho thấy sự phân bố cụ thể của các dự đoán:

- **Lớp "Có bệnh" (Positive):** Mô hình nhận diện đúng **94/102** ca bệnh thực tế (Recall 92.16%). Việc chỉ bỏ sót 8 ca bệnh là một kết quả rất ấn tượng trong bài toán y tế.
- **Lớp "Không bệnh" (Negative):** Mô hình nhận diện đúng **67/82** ca khỏe mạnh. Có 15 ca bị dự đoán nhầm (False Positive).

- **Độ chính xác dự đoán (Precision):** Khi mô hình dự đoán "Có bệnh", xác suất đúng đạt **86%**.

Phân tích đường cong ROC

Đường cong ROC (Receiver Operating Characteristic) nằm sát góc trên bên trái với diện tích dưới đường cong **AUC = 0.9189**.



Hình 8: ROC Curve – AUC = 0.9189

- Giá trị $AUC > 0.9$ khẳng định Random Forest có khả năng tách biệt (separation) cực kỳ tốt giữa hai lớp dữ liệu.
- Độ dốc của đường cong ở giai đoạn đầu cho thấy mô hình có thể đạt được True Positive Rate rất cao trong khi vẫn giữ False Positive Rate ở mức thấp.

7 Thảo luận và So sánh hiệu năng các mô hình

Sau quá trình tinh chỉnh siêu tham số và huấn luyện toàn diện, hiệu suất của ba mô hình được tổng hợp và đối chiếu trên cùng một tập kiểm thử độc lập (Test set) gồm 184 mẫu. Kết quả định lượng được trình bày trong Bảng 8 .

Bảng 8: Bảng tổng hợp và so sánh hiệu suất các mô hình

Thuật toán	Accuracy	Sensitivity (Recall)	Specificity	ROC-AUC
Decision Tree	82.61%	90.20%	73.17%	0.8873
Logistic Regression	83.70%	87.00%	79.00%	0.896
Random Forest	87.50%	92.16%	81.71%	0.9189

Dựa trên các chỉ số thực nghiệm và biểu đồ ROC, nhóm nghiên cứu rút ra các luận điểm phân tích chuyên sâu như sau:

7.1 Sự ưu việt của mô hình Ensemble (Random Forest)

Thuật toán **Random Forest** thể hiện sự áp đảo toàn diện ở các thước đo quan trọng nhất: Accuracy (87.50%), ROC-AUC (0.9189) và đặc biệt là **Độ nhạy - Recall (92.16%)**. Trong hệ quy chiếu của bài toán y khoa, Recall là thước đo mang tính "sống còn". Rủi ro từ việc bỏ sót một bệnh nhân (False Negative) mang lại hậu quả lâm sàng nghiêm trọng hơn rất nhiều so với việc cảnh báo nhầm (False Positive). Bằng cơ chế kết hợp hàng trăm cây quyết định độc lập và lựa chọn đặc trưng ngẫu nhiên (Bagging), Random Forest đã triệt tiêu hiệu quả phương sai (Variance) cao của mô hình cây đơn lẻ, giúp

thuật toán sở hữu sức đề kháng cực tốt trước các nhiễu loạn từ dữ liệu nội suy.

7.2 Sức mạnh dự đoán của Logistic Regression

Dù thuộc nhóm mô hình tuyến tính đơn giản, **Logistic Regression** vẫn đạt mức ROC-AUC xuất sắc (0.9085) và sở hữu chỉ số Độ đặc hiệu - Specificity cao (79.00%). Thành tựu này minh chứng cho chất lượng ưu việt của quá trình tiền xử lý dữ liệu: Việc áp dụng **RobustScaler** để làm dịu các giá trị ngoại lai và **KNNImputer** để nội suy dữ liệu đã kiến tạo một không gian đặc trưng mượt mà, tạo điều kiện lý tưởng để thuật toán tuyến tính hội tụ. Với Specificity cao (kiểm soát tốt rủi ro dương tính giả), mô hình này hoàn toàn có tiềm năng ứng dụng tại các hệ thống sàng lọc y tế tuyến cơ sở, nơi tài nguyên y tế cần được tối ưu hóa.

7.3 Giới hạn và Giá trị của Decision Tree

Mô hình **Decision Tree** ghi nhận hiệu năng khiêm tốn nhất trong nhóm (Accuracy 82.61%, AUC 0.8873). Dù đã trải qua quá trình dò tìm lưới (Grid Search) nghiêm ngặt và tối ưu hóa ngưỡng cắt (Threshold Tuning $\tau = 0.37$), cây quyết định vẫn bộc lộ điểm yếu cố hữu về hiện tượng quá khớp (Overfitting). Mặc dù vậy, giá trị cốt lõi của Decision Tree không nằm ở độ chính xác tối đa, mà nằm ở **tính minh bạch (White-box model)**. Khả năng diễn dịch toàn bộ cấu trúc dự đoán thành các tập luật (*IF-THEN*) tường minh giúp các y bác sĩ dễ dàng tham chiếu, tăng cường độ tin cậy vào hệ thống ra quyết định.

Tổng kết: Khi đánh giá toàn diện dựa trên mục tiêu tối thượng là phát hiện sớm và chính xác nguy cơ bệnh lý tim mạch, **Random Forest** là giải pháp trọn vẹn nhất. Mô hình thiết lập được trạng thái cân bằng lý tưởng giữa khả năng bao quát ca bệnh (Recall > 92%), độ chính xác tổng thể ấn tượng và tính ổn định vượt trội trên dữ liệu ngoại lai.

8 Kết luận và Hướng phát triển

8.1 Kết luận

Nghiên cứu này đã trình bày và thực thi thành công một quy trình Khoa học dữ liệu (Data Science pipeline) toàn diện, từ khâu làm sạch, xử lý độ lệch dữ liệu, cho đến tối ưu hóa và đánh giá các mô hình học máy nhằm chẩn đoán sớm bệnh tim mạch. Thông qua quá trình thực nghiệm, nhóm rút ra các kết luận trọng tâm sau:

- **Tầm quan trọng của Tiền xử lý dữ liệu:** Việc ứng dụng các kỹ thuật nội suy nâng cao (KNNImputer) để khôi phục dữ liệu khuyết thiếu kết hợp với kỹ thuật sinh mẫu nhân tạo (SMOTE) đã giải quyết triệt để sự thiếu hụt và mất cân bằng của dữ liệu y tế gốc. Điều này tạo nền tảng vững chắc giúp các mô hình không bị học lệch.
- **Hiệu suất vượt trội của mô hình Ensemble:** Mặc dù Cây quyết định và Hồi quy Logistic đều cho kết quả khả quan (Accuracy $\approx 82 - 84\%$), thuật toán **Random Forest** đã chứng minh sự ưu việt tuyệt đối. Với $AUC = 0.9189$ và đặc biệt là Độ nhạy (Recall) đạt **92.16%**, mô hình đã giảm thiểu tối đa tỷ lệ dương tính giả (bỏ sót bệnh nhân) - một tiêu chí mang tính sống còn trong hỗ trợ quyết định lâm sàng.
- **Khả năng giải thích (Explainability):** Mô hình không chỉ hoạt động như một "hộp đen" mà còn trích xuất thành công các triệu chứng có trọng số ảnh hưởng lớn nhất (đau thắt ngực, nhịp tim tối đa, chỉ số vống ST), hoàn toàn tương thích với các nguyên lý y khoa hiện đại.

8.2 Hướng phát triển tương lai

Mặc dù đạt được những kết quả khả quan, hệ thống vẫn còn tiềm năng nâng cấp để tiến gần hơn đến khả năng ứng dụng trong thực tế tại các bệnh viện. Nhóm nghiên cứu đề xuất các hướng phát triển tiếp theo bao gồm:

- **Mở rộng quy mô tập dữ liệu:** Thu thập thêm dữ liệu từ đa dạng

nguồn nhân khẩu học, độ tuổi và vùng địa lý nhằm kiểm chứng tính tổng quát hóa của mô hình và giảm thiểu các thiên kiến (bias) tiềm ẩn.

- **Tích hợp Trí tuệ nhân tạo có thể giải thích (Explainable AI - XAI):** Ứng dụng các thư viện như SHAP (SHapley Additive exPlanations) hay LIME để giải thích chi tiết quyết định của mô hình cho từng bệnh nhân cụ thể. Điều này sẽ củng cố niềm tin của các y bác sĩ khi sử dụng hệ thống.
- **Khảo sát các thuật toán tiên tiến:** So sánh hiệu năng của Random Forest với các thuật toán Boosting hiện đại (như XGBoost, LightGBM) hoặc các kiến trúc Học sâu (Deep Learning) chuyên biệt cho dữ liệu dạng bảng như TabNet.
- **Triển khai phần mềm ứng dụng (Deployment):** Xây dựng một giao diện Web/API hoặc ứng dụng di động cho phép các chuyên gia y tế nhập trực tiếp các chỉ số xét nghiệm và nhận được kết quả cảnh báo nguy cơ theo thời gian thực.

9 Tài liệu tham khảo

- UC Irvine Machine Learning Repository: <https://archive.ics.uci.edu/>
- Kaggle Datasets: <https://www.kaggle.com/datasets>
- Danh sách tổng hợp: https://en.wikipedia.org/wiki/List_of_datasets_for_machinelearning_research